GNN lai cục bộ-toàn cục với cổng theo nút dựa trên proxy homophily không nhãn cho phân loại nút trên đồ thị heterophilic

Thai V. Nguyen

Ngày 1 tháng 9 năm 2026

Mục lục

1 Định nghĩa bài toán **2**
1.1 Ký hiệu . . . 2
1.2 Bài toán phân loại nút . . . 2
1.3 Định lượng homophily . . . 3

2 Câu hỏi nghiên cứu và mục tiêu dự án **4**

3 Phương pháp đề xuất **4**
3.1 Kiến trúc tổng thể . . . 4
3.2 Nhánh cục bộ . . . 5
3.3 Nhánh không cục bộ với restricted attention . . . 5
3.4 Proxy homophily không nhãn . . . 8
3.5 Node-wise gate với đường tín hiệu tường minh . . . 8
3.6 Bộ phân loại và hàm mất mát . . . 10
3.7 Thuật toán . . . 10
3.8 Thiết kế thực nghiệm . . . 11

4 Kết quả và đóng góp dự kiến **12**

Tài liệu tham khảo **14**

1 Định nghĩa bài toán

1.1 Ký hiệu

Cho một đồ thị $G = (V, E)$, $V = \{v_1, \ldots, v_N\}$ với $N = |V|$ nút và E là tập cạnh. Với các bộ dữ liệu chính được sử dụng trong dự án, G được xét dưới dạng đồ thị vô hướng.

Gọi:

- $\mathbf{X} \in \mathbb{R}^{N \times d}$ là ma trận đặc trưng nút, trong đó hàng thứ v là vector $\mathbf{x}_v \in \mathbb{R}^d$ của nút v;
- $\mathbf{A} = \{0, 1\}^{N \times N}$ là ma trận kề, với

$$A_{uv} = \begin{cases} 1, & \text{nếu } \{u, v\} \in E, \\ 0, & \text{ngược lại;} \end{cases} \tag{1.1}$$

- $\mathcal{N}(v) = \{u \in V : \{u, v\} \in E\}$ là tập lân cận một bước;
- $d_v = |\mathcal{N}(v)|$ là bậc của nút v;
- $y_v \in \{1, \ldots, C\}$ là nhãn thật của nút v.

Tập nút được chia thành $V_{\text{train}}, V_{\text{val}}, V_{\text{test}}$ (tương ứng với tập nút huấn luyện, kiểm định và kiểm tra) thỏa mãn

$$V_{\text{train}} \cap V_{\text{val}} = V_{\text{train}} \cap V_{\text{test}} = V_{\text{val}} \cap V_{\text{test}} = \emptyset \tag{1.2}$$

và

$$V_{\text{train}} \cup V_{\text{val}} \cup V_{\text{test}} = V. \tag{1.3}$$

1.2 Bài toán phân loại nút

Cho đồ thị $G = (V, E)$, ma trận đặc trưng $\mathbf{X}$ và nhãn $\{y_v : v \in V_{\text{train}}\}$. Trong thiết lập transductive semi-supervised node classification, $\mathbf{A}$ và $\mathbf{X}$ của toàn bộ đồ thị được quan sát trong quá trình huấn luyện, trong khi đó, nhãn của V_{train} được sử dụng để tối ưu tham số. Mục tiêu là học một hàm $f_\Theta : (\mathbf{A}, \mathbf{X}) \mapsto \mathbf{P} \in [0, 1]^{N \times C}$, trong đó P_{vc} là xác suất nút v thuộc lớp c được định nghĩa như sau:

$$P_{vc} = P_\Theta(y_v = c \mid \mathbf{A}, \mathbf{X}), \quad \sum_{c=1}^{C} P_{vc} = 1. \tag{1.4}$$

Tham số mô hình được học bằng

$$\Theta^* = \arg\min_{\Theta} \mathcal{L}_{\text{train}}(\Theta). \tag{1.5}$$

Tập V_{val} chỉ được sử dụng để lựa chọn mô hình và siêu tham số, trong khi V_{test} chỉ được sử dụng để đánh giá khả năng tổng quát hóa cuối cùng.

1.3 Định lượng homophily

Định nghĩa 1.1 (Edge homophily)**.** Edge homophily của đồ thị G được định nghĩa bởi

$$h_{\text{edge}}(G) = \frac{|\{\{u, v\} \in E : y_u = y_v\}|}{|E|}. \tag{1.6}$$

Đại lượng này biểu diễn tỷ lệ cạnh nối hai nút cùng nhãn.

Định nghĩa 1.2 (Local node homophily)**.** Với một nút v có $d_v > 0$, local node homophily của v được định nghĩa bởi

$$h_{\text{node}}(v) = \frac{1}{d_v} \sum_{u \in \mathcal{N}(v)} \mathbb{I}[y_u = y_v]. \tag{1.7}$$

Đặt $V_+ = \{v \in V : d_v > 0\}$, node homophily trung bình của đồ thị được xác định bởi

$$h_{\text{node}}(G) = \frac{1}{|V_+|} \sum_{v \in V_+} h_{\text{node}}(v). \tag{1.8}$$

Nhận xét 1.1. Đại lượng $h_{\text{node}}(v)$ phụ thuộc trực tiếp vào nhãn thật của các nút lân cận. Vì vậy, trong dự án này nó chỉ được sử dụng như một oracle quantity cho phân tích hậu nghiệm và tuyệt đối không được đưa vào mô hình trong quá trình huấn luyện hoặc suy luận.

Edge homophily có cách diễn giải trực quan nhưng không có cùng baseline khi số lớp hoặc mức mất cân bằng lớp thay đổi. Vì lý do đó, ta đề xuất sử dụng adjusted homophily khi cần so sánh mức homophily giữa các đồ thị.

Định nghĩa 1.3 (Adjusted homophily)**.** Với $D_c = \sum_{v:y_v=c} d_v$ là tổng bậc của các nút thuộc lớp c, đặt

$$\bar{p}(c) = \frac{D_c}{2|E|}. \tag{1.9}$$

Adjusted homophily được định nghĩa bởi

$$h_{\text{adj}}(G) = \frac{h_{\text{edge}}(G) - \sum_{c=1}^{C} \bar{p}(c)^2}{1 - \sum_{c=1}^{C} \bar{p}(c)^2}. \tag{1.10}$$

Nhận xét 1.2. Trong dự án này không sử dụng quy tắc $h_{\text{edge}} < 0.5$ để định nghĩa một đồ thị là heterophilic. Nguyên nhân là edge homophily phụ thuộc vào số lớp và phân bố lớp. Do đó, một ngưỡng cố định như 0.5 không tạo ra một tiêu chuẩn thống nhất giữa các bộ dữ liệu . Thay vào đó, mức độ heterophily của mỗi bộ dữ liệu được mô tả thông qua nhiều thống kê như h_{edge} và h_{adj}.

Một đặc điểm quan trọng của bài toán là $h_{\text{node}}(v)$ có thể biến thiên đáng kể giữa các nút trong cùng một đồ thị. Do đó, ngay cả khi một đồ thị có mức heterophily cao ở cấp độ toàn cục, một số nút vẫn có thể nằm trong các lân cận tương đối homophilic, trong khi các nút khác nằm trong các vùng mạnh về heterophily. Quan sát này tạo động lực cho một cơ chế thích ứng ở cấp độ nút thay vì sử dụng cùng một chiến lược tổng hợp cho toàn bộ đồ thị.

2 Câu hỏi nghiên cứu và mục tiêu dự án

Dự án tập trung trả lời 3 câu hỏi nghiên cứu sau:

- Tín hiệu tương đồng đặc trưng cục bộ không nhãn có tương quan với local label homophily thật. Quan trọng hơn, nó có dự đoán được lợi ích tương đối của nhánh cục bộ so với nhánh phi cục bộ hay không?
- Việc đưa tín hiệu proxy homophily tường minh vào một node-wise gate có cải thiện hiệu quả phân loại so với local-only, global-only, fixed fusion và learned gate không sử dụng proxy hay không, khi tất cả các phương pháp được tinh chỉnh với cùng budget?
- Restricted non-local attention sử dụng Top-k nút tương đồng về đặc trưng có tạo ra trade-off hợp lý giữa hiệu quả dự đoán và chi phí tính toán so với random-k, local-only và, trên các đồ thị đủ nhỏ, full global attention hay không?

3 Phương pháp đề xuất

3.1 Kiến trúc tổng thể

Mô hình đề xuất gồm 3 thành phần chính:

(i) một nhánh cục bộ dựa trên message-passing GNN,

(ii) một nhánh toàn cục dựa trên restricted attention,

(iii) một node-wise gate kết hợp 2 nhánh và nhận thêm một proxy homophily không nhãn dưới dạng tín hiệu tường minh.

Đầu tiên, đặc trưng gốc được ánh xạ vào cùng một không gian tiềm ẩn

$$\mathbf{H}^{(0)} = \phi_{\text{in}}(\mathbf{X}) \in \mathbb{R}^{N \times d_h}. \tag{3.1}$$

Việc sử dụng cùng một embedding dimension cho hai nhánh giúp phép kết hợp sau đó được xác định một cách nhất quán.

3.2 Nhánh cục bộ

Nhánh cục bộ sử dụng GCN làm kiến trúc mặc định. Đặt $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ và $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$. Một lớp GCN được viết dưới dạng

$$\mathbf{H}^{(\ell+1)} = \sigma\left(\tilde{\mathbf{D}}^{-1/2}\tilde{\mathbf{A}}\tilde{\mathbf{D}}^{-1/2}\mathbf{H}^{(\ell)}\mathbf{W}^{(\ell)}\right). \tag{3.2}$$

Sau L_{local} lớp,

$$\mathbf{z}_v^L = \mathbf{H}_v^{(L_{\text{local}})}. \tag{3.3}$$

Nhận xét 3.1. GCN được lựa chọn không phải vì nó được giả định là tối ưu trên heterophily, mà vì GCN là một baseline message-passing chuẩn và các kết quả gần đây cho thấy GCN/GAT/GraphSAGE được tinh chỉnh đúng có thể là những baseline rất mạnh . Do đó, các yếu tố như dropout, residual connection, normalization, hidden dimension và số lớp sẽ được lựa chọn bằng validation thay vì cố định tùy ý.

Ngoài GCN, GAT được sử dụng trong một thí nghiệm độ nhạy để kiểm tra liệu kết luận của dự án có phụ thuộc mạnh vào bộ mã hóa cục bộ hay không. Với GAT, hệ số attention có dạng

$$\alpha_{ij} = \frac{\exp\left(\text{LeakyReLU}\left(\mathbf{a}^\top[\mathbf{W}\mathbf{h}_i \,\|\, \mathbf{W}\mathbf{h}_j]\right)\right)}{\sum_{k \in \mathcal{N}(i)} \exp\left(\text{LeakyReLU}\left(\mathbf{a}^\top[\mathbf{W}\mathbf{h}_i \,\|\, \mathbf{W}\mathbf{h}_k]\right)\right)}. \tag{3.4}$$

3.3 Nhánh không cục bộ với restricted attention

Full self-attention trên toàn bộ N nút có độ phức tạp bậc hai và có thể gặp hiện tượng over-globalizing . Do đó, với mỗi nút v, chỉ lựa chọn $k \ll N$ ứng viên phi cục bộ.

Để nhánh attention thực sự biểu diễn tín hiệu ngoài lân cận một bước, ta loại nút v và các nút kề trực tiếp khỏi tập ứng viên. Đặt

$$\mathcal{U}(v) = V \setminus \big(\{v\} \cup \mathcal{N}(v)\big), \qquad k_v = \min\{k, |\mathcal{U}(v)|\}.$$

Tập ứng viên gồm tối đa k nút trong $\mathcal{U}(v)$ có độ tương đồng cosine với v cao nhất:

$$\mathcal{C}_k(v) = \mathrm{TopK}_{u \in \mathcal{U}(v),\, k_v} \left(\bar{x}_v^\top \bar{x}_u \right).$$

Nếu $\mathcal{U}(v) = \varnothing$, ta quy ước $z_v^G = \mathbf{0}$. Trong các bộ dữ liệu thực nghiệm, điều kiện này sẽ được kiểm tra trước khi huấn luyện.

Các nút lân cận một bước bị loại khỏi $\mathcal{C}_k(v)$ nhằm giảm sự trùng lặp trực tiếp giữa nhánh cục bộ và nhánh toàn cục.

Nhận xét 3.2. Một nút nằm ngoài $\mathcal{N}(v)$ chưa chắc đã là một nút rất xa theo khoảng cách đồ thị. Nó có thể chỉ cách v hai bước. Vì vậy, $\mathcal{C}_k(v)$ được gọi là tập ứng viên không cục bộ thay vì mặc định gọi là tập các phần tử xa đồ thị. (Ablation: kiểm tra thêm trường hợp loại cả lân cận hai bước)

Attention được thực hiện trên các hidden representation

$$\mathbf{q}_v = \mathbf{W}_Q \mathbf{h}_v^{(0)}, \quad \mathbf{k}_u = \mathbf{W}_K \mathbf{h}_u^{(0)}, \quad \mathbf{r}_u = \mathbf{W}_V \mathbf{h}_u^{(0)}. \tag{3.5}$$

Với $u \in \mathcal{C}_k(v)$,

$$e_{vu} = \frac{\mathbf{q}_v^\top \mathbf{k}_u}{\sqrt{d_k}}, \tag{3.6}$$

và

$$\beta_{vu} = \frac{\exp(e_{vu})}{\sum_{u' \in \mathcal{C}_k(v)} \exp(e_{vu'})}. \tag{3.7}$$

Đầu ra của nhánh không cục bộ là

$$\mathbf{z}_v^G = \sum_{u \in \mathcal{C}_k(v)} \beta_{vu} \mathbf{r}_u. \tag{3.8}$$

Độ phức tạp tính toán. Sau khi tập ứng viên đã được tạo, restricted attention có độ phức tạp xấp xỉ $\mathcal{O}(Nkd_h)$. Tuy nhiên, cần tính cả chi phí xây dựng $\mathcal{C}_k(v)$. Tổng chi phí được mô tả chính xác hơn bởi

$$T_{\text{total}} = T_{\text{retrieval}} + \mathcal{O}(Nkd_h). \tag{3.9}$$

Nếu thực hiện exact nearest-neighbor search bằng cách so sánh mọi cặp nút thì

$$T_{\text{retrieval}} = \mathcal{O}(N^2 d). \tag{3.10}$$

Do đó, trong implementation dự kiến, tập ứng viên được precompute một lần trước quá trình huấn luyện bằng blockwise Top-k hoặc approximate nearest neighbor search. Sau đó chi phí attention trong mỗi epoch chỉ phụ thuộc tuyến tính vào Nk.

3.4 Proxy homophily không nhãn

Với mỗi nút v có $d_v > 0$, định nghĩa Trước khi tính độ tương đồng, mỗi vector đặc trưng được chuẩn hóa theo chuẩn ℓ_2:

$$\bar{x}_v = \begin{cases} \dfrac{x_v}{\|x_v\|_2}, & \|x_v\|_2 > 0, \\ \mathbf{0}, & \|x_v\|_2 = 0. \end{cases}$$

Do đó, $\bar{x}_v^\top \bar{x}_u$ là độ tương đồng cosine khi cả hai vector đều khác vector không. Với vector đặc trưng bằng không, độ tương đồng được xem là bằng 0.

$$s_v = \frac{1}{d_v} \sum_{u \in \mathcal{N}(v)} \bar{\mathbf{x}}_v^\top \bar{\mathbf{x}}_u. \tag{3.11}$$

Đại lượng s_v chỉ sử dụng đặc trưng và cấu trúc đồ thị, không sử dụng nhãn nút. Local node homophily $h_{\text{node}}(v)$ chỉ được tính sau khi hoàn tất thí nghiệm để phân tích hậu nghiệm; đại lượng này không được dùng làm đầu vào, tinh chỉnh siêu tham số hoặc lựa chọn checkpoint.

Với nút cô lập, $s_v = 0$. Sau đó, chuẩn hóa trên toàn đồ thị

$$\tilde{s}_v = \frac{s_v - \mu_s}{\sigma_s + \varepsilon}. \tag{3.12}$$

Bậc nút cũng được biến đổi và chuẩn hóa

$$\tilde{d}_v = \text{Standardize}\left(\log(1 + d_v)\right). \tag{3.13}$$

Định nghĩa 3.1 (Proxy homophily không nhãn)**.** Trong dự án này, s_v được gọi là proxy homophily không nhãn theo nghĩa nó là một thống kê quan sát được từ đặc trưng và cấu trúc đồ thị, được giả thuyết là có thể mang thông tin về mức độ tin cậy của lân cận cục bộ. Thuật ngữ proxy không hàm ý rằng $s_v = h_{\text{node}}(v)$ hoặc rằng hai đại lượng luôn có tương quan mạnh.

3.5 Node-wise gate với đường tín hiệu tường minh

Thay vì đưa s_v vào cùng một MLP lớn như một đặc trưng thông thường, dự án sử dụng một đường tín hiệu riêng:

$$\alpha_v = \sigma\left(\gamma \tilde{s}_v + g_\theta\left([\tilde{d}_v \,\|\, \mathbf{z}_v^L \,\|\, \mathbf{z}_v^G]\right)\right), \quad \alpha_v \in (0,1), \tag{3.14}$$

trong đó g_θ là một MLP hai lớp nhỏ và γ là một tham số scalar học được.

Trong thiết lập chính, γ không bị ràng buộc dấu. Điều này tránh việc áp đặt trước giả định rằng similarity đặc trưng cao luôn hàm ý nhánh cục bộ đáng tin cậy hơn. Một phiên bản $\gamma = \text{softplus}(\rho) \geq 0$ sẽ được xem xét trong ablation study.

Biểu diễn cuối cùng của nút v là

$$\mathbf{z}_v = \alpha_v \mathbf{z}_v^L + (1 - \alpha_v)\mathbf{z}_v^G. \tag{3.15}$$

Nhận xét 3.3. Việc đưa s_v vào gate không được xem là một dạng regularization theo nghĩa toán học. Vai trò chính của đường tín hiệu tường minh là làm cho cơ chế gating dễ diễn giải và dễ kiểm chứng hơn: có thể phân tích trực tiếp mối quan hệ giữa s_v, α_v, oracle local homophily và hiệu quả tương đối của hai nhánh.

3.6 Bộ phân loại và hàm mất mát

Với bài toán đa lớp,

$$\mathbf{o}_v = \mathbf{W}_{\text{out}}\mathbf{z}_v + \mathbf{b}, \tag{3.16}$$

và

$$\hat{\mathbf{y}}_v = \text{softmax}(\mathbf{o}_v). \tag{3.17}$$

Cross-entropy loss được tính trên tập huấn luyện

$$\mathcal{L}_{\text{CE}} = -\frac{1}{|V_{\text{train}}|} \sum_{v \in V_{\text{train}}} \log \hat{y}_{v,y_v}. \tag{3.18}$$

Với các bài toán nhị phân, sử dụng một logit o_v và

$$p_v = \sigma(o_v). \tag{3.19}$$

Binary cross-entropy được định nghĩa bởi

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|V_{\text{train}}|} \sum_{v \in V_{\text{train}}} \left[y_v \log p_v + (1 - y_v) \log(1 - p_v) \right]. \tag{3.20}$$

Hàm mất mát tổng quát có dạng

$$\mathcal{L} = \mathcal{L}_{\text{CE/BCE}} + \lambda \|\Theta\|_2^2, \tag{3.21}$$

trong đó λ được lựa chọn bằng validation.

3.7 Thuật toán

Các đại lượng $\bar{\mathbf{X}}$, $\{s_v\}_{v \in V}$ và $\{\mathcal{C}_k(v)\}_{v \in V}$ được precompute trước quá trình huấn luyện vì chúng chỉ phụ thuộc vào đặc trưng và cấu trúc đồ thị.

Algorithm 1 Forward pass của mô hình local–global đề xuất

Require: Đồ thị $G = (V, E)$; ma trận đặc trưng $\mathbf{X}$; tập ứng viên $\{\mathcal{C}_k(v)\}_{v \in V}$; proxy $\{\tilde{s}_v\}_{v \in V}$; degree feature $\{\tilde{d}_v\}_{v \in V}$.
Ensure: Logit dự đoán $\mathbf{O}$ cho mọi nút.

$\mathbf{H}^{(0)} \leftarrow \phi_{\text{in}}(\mathbf{X})$
$\mathbf{Z}^L \leftarrow f_{\text{local}}(\mathbf{H}^{(0)}, \mathbf{A})$
$\mathbf{Z}^G \leftarrow f_{\text{global}}\left(\mathbf{H}^{(0)}, \{\mathcal{C}_k(v)\}_{v \in V}\right)$
for each $v \in V$ **do**
    $\alpha_v \leftarrow \sigma\left(\gamma \tilde{s}_v + g_\theta([\tilde{d}_v; \mathbf{z}_v^L; \mathbf{z}_v^G])\right)$
    $\mathbf{z}_v \leftarrow \alpha_v \mathbf{z}_v^L + (1 - \alpha_v)\mathbf{z}_v^G$
end for
$\mathbf{O} \leftarrow \mathbf{Z}\mathbf{W}_{\text{out}} + \mathbf{b}$
return $\mathbf{O}$

3.8 Thiết kế thực nghiệm

Bộ dữ liệu và giao thức. Thực nghiệm chính sử dụng hai bộ dữ liệu heterophily Roman-empire và Minesweeper thuộc benchmark được công bố bởi Platonov và cộng sự [5]. Hai bộ dữ liệu này đại diện cho bài toán phân loại đa lớp và nhị phân. Nhóm sử dụng phiên bản dữ liệu và cách chia tập được phát hành cùng benchmark, đồng thời ghi lại nguồn dữ liệu, phiên bản và các thông số cơ bản của từng đồ thị trong báo cáo.

Đây là thiết lập transductive: đặc trưng và cấu trúc đồ thị của toàn bộ các nút được quan sát trong quá trình huấn luyện, nhưng chỉ nhãn của tập huấn luyện được dùng để tối ưu mô hình. Nhãn validation chỉ được dùng cho early stopping và lựa chọn siêu tham số. Nhãn test chỉ được dùng trong lần đánh giá cuối cùng.

Các mô hình đối chứng. Các phương pháp sau được so sánh trên cùng tập dữ liệu và cùng giao thức:

1. MLP, chỉ sử dụng đặc trưng nút;
2. GCN local-only, chỉ sử dụng nhánh cục bộ;
3. restricted attention global-only, chỉ sử dụng nhánh attention;
4. fixed fusion, kết hợp hai nhánh với trọng số cố định $\alpha_v = 0.5$;
5. learned gate, sử dụng cổng học được nhưng bỏ thành phần proxy $\gamma\widetilde{s}_v$;
6. proposed gate, mô hình đầy đủ có proxy tương đồng tường minh.

Các mô hình được tinh chỉnh với cùng ngân sách tìm kiếm và cùng quy tắc early stopping. Kết quả từ bài báo gốc chỉ được dùng làm tham khảo nếu split, tiền xử lý và giao thức đánh giá tương thích với thí nghiệm này.

Chỉ số đánh giá và độ ổn định. Accuracy là chỉ số chính; macro-F1 được báo cáo bổ sung để phản ánh hiệu quả trên các lớp có tần suất khác nhau. Mỗi cấu hình được chạy trên các seed hoặc split do benchmark cung cấp. Kết quả được trình bày dưới dạng trung bình và độ lệch chuẩn:

$$\text{mean} \pm \text{std}.$$

Nhóm báo cáo số seed/split thực tế đã chạy và không chọn lại seed dựa trên kết quả test.

Ngoài chất lượng phân loại, nhóm ghi nhận thời gian tạo tập ứng viên $\mathcal{C}_k(v)$, thời gian mỗi epoch và tổng thời gian huấn luyện. Nếu môi trường cho phép, nhóm cũng báo cáo bộ nhớ đỉnh. Thời gian truy xuất ứng viên được đo riêng với thời gian attention sau khi đã có danh sách ứng viên.

Thí nghiệm ablation. Các ablation chính gồm:

1. bỏ proxy khỏi cổng để so sánh với learned gate;
2. hoán vị giá trị proxy giữa các nút để kiểm tra liệu việc gắn proxy với đúng nút có quan trọng hay không;
3. thay tập ứng viên Top-k theo similarity bằng tập random-k.

Full attention chỉ được chạy trên bộ dữ liệu đủ nhỏ và nếu bộ nhớ cho phép. Đây là thí nghiệm mở rộng, không phải điều kiện bắt buộc để hoàn thành project.

Sau khi hoàn tất đánh giá, nhóm phân tích tương quan giữa s_v và $h_{\text{node}}(v)$, cũng như mối quan hệ giữa s_v, giá trị cổng α_v và kết quả dự đoán. Phân tích này chỉ nhằm giải thích kết quả, không được dùng để chọn mô hình hoặc siêu tham số.

Nguyên tắc kết luận. Nếu proposed gate cải thiện ổn định so với learned gate trong cùng ngân sách tinh chỉnh, kết quả cung cấp bằng chứng rằng proxy có ích trên các bộ dữ liệu đã thử. Nếu proxy tương quan yếu với local node homophily, hoặc mô hình dùng proxy không tốt hơn learned gate, nhóm sẽ kết luận rằng thí nghiệm chưa cho thấy proxy mang lại lợi ích rõ ràng trong thiết lập này. Kết quả đó vẫn có giá trị vì dự án kiểm tra giả thuyết bằng đối chứng cụ thể, thay vì giả định trước mô hình phải vượt baseline.

4 Kết quả và đóng góp dự kiến

Proxy s_v được kỳ vọng cung cấp tín hiệu hữu ích trên các bộ dữ liệu mà độ tương đồng đặc trưng phản ánh phần nào độ tin cậy của lân cận cục bộ. Trong những trường hợp đó, explicit gate có thể cải thiện so với fixed fusion hoặc learned-only gate. Ngược lại, nếu feature–label alignment yếu, s_v có thể có tương quan thấp với local homophily và không đem lại cải thiện đáng kể.

Các đóng góp dự kiến của dự án gồm:

1. xây dựng một protocol đánh giá tái lập được cho node-wise local–global routing trên các benchmark heterophily hiện đại;
2. định lượng mối quan hệ giữa feature-based proxy s_v, oracle local homophily $h_{\text{node}}(v)$, giá trị gate α_v và lợi ích tương đối của hai nhánh;
3. đánh giá liệu việc đưa một tín hiệu không nhãn tường minh vào gate có tạo ra lợi ích vượt quá capacity của một learned-only gate hay không;
4. phân tích trade-off giữa local aggregation, restricted non-local attention và chi phí tính toán.

Nhận xét 4.1. Dự án không giả định trước rằng mô hình đề xuất sẽ vượt tất cả các baseline. Một kết quả âm vẫn có giá trị khoa học. Chẳng hạn, nếu shuffled proxy cho kết quả tương đương proxy thật hoặc Spearman$(s_v, h_{\text{node}}(v))$ gần bằng 0, kết luận phù hợp là proxy được đề xuất chưa cung cấp bằng chứng đủ mạnh cho cơ chế định tuyến, thay vì lựa chọn lại dataset hoặc hyperparameter chỉ để duy trì giả thuyết ban đầu.

Tài liệu tham khảo

Tài liệu

[1] T. N. Kipf and M. Welling. Semi-Supervised Classification with Graph Convolutional Networks. *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1609.02907

[2] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. Graph Attention Networks. *International Conference on Learning Representations (ICLR)*, 2018. https://arxiv.org/abs/1710.10903

[3] H. Pei et al. Geom-GCN: Geometric Graph Convolutional Networks. *International Conference on Learning Representations (ICLR)*, 2020. https://arxiv.org/abs/2002.05287

[4] J. Zhu et al. Beyond Homophily in Graph Neural Networks: Current Limitations and Effective Designs. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. https://arxiv.org/abs/2006.11468

[5] O. Platonov, D. Kuznedelev, M. Diskin, A. Babenko, and L. Prokhorenkova. A Critical Look at the Evaluation of GNNs Under Heterophily: Are We Really Making Progress? *International Conference on Learning Representations (ICLR)*, 2023. https://arxiv.org/abs/2302.11640